

ML examen

notas:

Objetivo de Machine Learning (¿Cómo con datos?): Es la traducción técnica del objetivo de negocio en una tarea predictiva o de optimización.

Responde:

- **¿Qué tipo de tarea de ML es? ¿Cuál es la variable objetivo (Target) y qué representa? ¿Qué datos se utilizarán para predecir? Cómo se medirá el éxito técnico?**
 - *Ejemplo en Fraude:* "Construir un modelo de clasificación binaria supervisado que clasifique transacciones financieras en tiempo real como legítimas (0) o fraudulentas (1), maximizando la métrica de Recall para la clase 1 (fraude) manteniendo la precisión por encima del 70%."

spearman relacion entre variables numericas, chi-cuadrado relacion variables categoricas

naive bayes gaussiano asume campana de gauss, numeros continuos

multinomial NB numero discretos, conteos

preprocesamiento para los modelos:

- **En Entrenamiento (Train):** Usamos `fit_transform()` (el escalador calcula la media y desviación estándar de los datos de entrenamiento y luego los escala).
- **En Prueba (Test):** Usamos `transform()` a secas.
- **¿Por qué?** Porque si calculas una nueva media y desviación estándar sobre los datos de prueba (`fit_transform` en test), estarías cometiendo **Data Leakage** (filtración de datos), asumiendo información del futuro que el modelo no debería conocer en la vida real.

¡Por supuesto! Esta es una **tabla de oro para tu examen**. Si te preguntan si un modelo requiere **Escalar (StandardScaler)** o si asume **Distribución Normal (Campana de Gauss)**, memoriza esta guía:

Tabla Resumen para el Examen (Cheat Sheet)

Modelo / Algoritmo	¿Requiere Escalar (StandardScaler)?	¿Requiere / Asume Distribución Normal?	¿Por qué? (Justificación de Examen)
KNN (K-Nearest Neighbors)	SÍ (Obligatorio)	No obligatoria	Porque se basa en distancias geométricas (Euclidianas). Si una variable es grande, aplastará a las pequeñas.
PCA (Dimensionality Reduction)	SÍ (Obligatorio)	No obligatoria	Busca las direcciones de máxima varianza . Sin escala, elegirá la variable con números más grandes por defecto.
Redes Neuronales (MLP)	SÍ (Obligatorio)	No obligatoria	El Descenso de Gradiente (Backpropagation) no converge bien con escalas diferentes; causa inestabilidad numérica.
SOM (Self-Organizing Maps)	SÍ (Obligatorio)	No obligatoria	Igual que KNN, agrupa neuronas basándose en distancias geométricas .
Naive Bayes (GaussianNB)	NO	SÍ (Campana de Gauss)	Funciona con conteo y probabilidad condicional (no distancias). Asume matemáticamente que los datos continuos son normales.
Random Forest / Árboles	NO	NO	Funciona mediante cortes o umbrales individuales (ej. ¿ <i>Edad</i> > 50?). Las variables no compiten ni se mezclan geométricamente.

3. Resumen de SOM en el examen

- Si preguntan por **preservación de topología**, la respuesta es SOM.
- Si preguntan por **reducción de dimensionalidad no lineal**, SOM es la opción.
- La **U-Matrix** es para detectar bordes entre grupos de datos.

1. ¿Cuándo usar KNN? Datos con pocos atributos, fronteras de decisión irregulares.
2. ¿Cuándo usar Naive Bayes? Clasificación de texto, grandes volúmenes de datos, atributos con poca correlación.
3. **Curse of Dimensionality**: KNN sufre mucho en alta dimensión; Naive Bayes es más resiliente.

- ¿KNN? Supervisado | Basado en Instancias.

- **¿Random Forest?** Supervisado | Ensamble (Divide y Vencerás / Bagging).
- **¿MLP?** Supervisado | Conexionista (Red Neuronal).
- **¿Naive Bayes?** Supervisado | Probabilístico (Bayesiano).
- **¿SOM?** No Supervisado | Topológico (Competitivo).
- **¿PCA?** No Supervisado | Proyección Lineal (Reducción de dimensiones).

knn:

- **K pequeño (ej. K=1):** El modelo es muy complejo. Se adapta demasiado a los datos (riesgo de **Overfitting** / Alta Varianza).
 - **K grande (ej. K=100):** El modelo es muy simple. Ignora patrones locales (riesgo de **Underfitting** / Alto Sesgo).
1. **Escalado: DEBES** usar `StandardScaler`. Como KNN usa distancias, si una variable es más grande que otra, arruinará el modelo.
 2. **Maldición de la Dimensionalidad:** En muchas dimensiones, los puntos se vuelven "lejanos" entre sí. Por eso, a menudo aplicamos **PCA** antes de KNN.

Insights:

- **La Matriz de Confusión**
- **Falsos Negativos (FN) - El Fraude no Detectado (El peor enemigo):**
 - *Qué significa:* El modelo predijo que la transacción era legítima (0), pero en realidad era fraude (1).
 - *Impacto de Negocio: Pérdida financiera directa.* El banco asume el costo de la estafa, o el cliente exige un reembolso por fondos robados.
- **Falsos Positivos (FP) - La Falsa Alarma (El dolor de cabeza):**
 - *Qué significa:* El modelo predijo que era fraude (1), pero en realidad era legítima (0).
 - *Impacto de Negocio: Fricción con el cliente e ineficiencia operativa.* El banco bloquea la tarjeta del cliente injustamente. El cliente se enoja, llama al Call Center (costo operativo) y puede decidir cambiarse de banco.

Precision vs. Recall

- **Recall (Sensibilidad):**

- *¿Qué responde?* Del total de fraudes **que realmente ocurrieron**, ¿cuántos logró detectar el modelo?
 - *Enfoque de Negocio:* Si tu prioridad es **seguridad absoluta**, quieres un Recall cercano a 1.0 (no dejar escapar nada).

- **Precision (Precisión):**

- *¿Qué responde?* De todas las alarmas de fraude **que el modelo encendió**, ¿cuántas resultaron ser fraudes reales?
 - *Enfoque de Negocio:* Si tu prioridad es **experiencia de usuario fluida**, quieres una Precisión alta (no molestar a clientes sanos con alarmas falsas).

hacer:

archivos usados

Clase_01_ML_Preprocesamiento_CriptoMonedas.ipynb

- **Preprocesamiento Básico**

Sem02_Imputacion_Valores_Faltantes.ipynb

- **Imputación de Valores Faltantes**

Sem02_DesClase_Outliers

- prueba shapiro-wilk
- tratamiento outliers capping (winsorizacion)

- **Detección de Outliers**

Sem02_Calculo_ZScore_Outliers.ipynb

- calculo del z score e identificacion de outliers con z score

Sem03_Clase_TransfDatos-Normalizacion.ipynb

- estandarizar con z-score (mediante standard scaler)

2.06_ML_Transformación_de_datos_PCA.ipynb

- PCA

07_ML_Naive_Bayes_Clasificador.ipynb

- aquí hay un sólido explorador de datos antes de usar los clasificadores.
- cross validation, naive bayes (gaussianNB)

08_ML_Naive_Bayes_Clasificador_Multinomial (1).ipynb

- clasificación de texto
- vectorización de texto
- multinomial naive bayes para texto

09_ML_Random_Forest_Clasificador.ipynb

- buen preprocesamiento
- random forest
- feature importance

10_01_ML_KNN_CLASIFICADOR_PCA.ipynb

- knn

10_02_ML_LQV_CLASIFICADOR_SOM_PCA.ipynb

- LVQ con minisom

10_ML_KNN_Clasificador_vs_NaiveBayes.ipynb

- NB vs KNN con varios k's

Pregunta 1: Imputación y Outliers (Semana 2)

Pregunta: "Tienes un dataset de clientes de un banco con valores faltantes en la columna 'Ingresos Mensuales'. Al analizar los datos, notas que hay unos

pocos clientes extremadamente ricos (outliers gigantes). ¿Qué técnica de imputación elegirías: la Media o la Mediana? Justifica tu respuesta."

- **Respuesta Ganadora:** Elegiría la **Mediana**.
- **Justificación:** La media es una medida altamente sensible a los valores extremos (outliers). Si usamos la media para imputar, los salarios de los clientes multimillonarios inflarían artificialmente el promedio general, rellenando los datos faltantes con valores irrealmente altos. La mediana es una métrica robusta ante outliers, por lo que mantendrá la imputación fiel a la realidad de la gran mayoría de los clientes.



Pregunta 2: El talón de Aquiles de Naive Bayes (Semana 7)

Pregunta: *"¿Por qué al clasificador Naive Bayes se le llama 'ingenuo' (Naive) y qué peligro corres al usarlo si dos de tus variables predictoras están altamente correlacionadas (ej. 'Estatura' y 'Talla de Calzado')?"*

- **Respuesta Ganadora:** Se le llama "ingenuo" porque asume la **independencia condicional** entre todas las variables predictoras; es decir, asume que el valor de una variable no tiene ninguna relación con el valor de otra.
- **El peligro:** Si dos variables están correlacionadas (como Estatura y Talla de Calzado), el modelo "contará dos veces" la misma información. Esto rompe la matemática interna de Bayes y provoca que el modelo calcule probabilidades extremadamente sesgadas (cercasas al 0% o al 100%), dando predicciones con una certeza artificialmente alta pero incorrecta.



Pregunta 3: Combatiendo el Overfitting en Random Forest (Semana 6)

Pregunta: *"Entrenas un modelo de Random Forest y obtienes un Accuracy del 100% en el conjunto de entrenamiento (Train), pero solo un 62% en el de prueba (Test). ¿Qué fenómeno está ocurriendo y qué 2 hiperparámetros modificarías específicamente para corregirlo?"*

- **Respuesta Ganadora:** Está ocurriendo **Sobreajuste (Overfitting)**. El modelo ha memorizado el ruido de los datos de entrenamiento y no es capaz de

generalizar ante datos nuevos.

- **Solución (Hiperparámetros):**

1. **Reducir** `max_depth` (**Profundidad Máxima**): Limitar la altura de los árboles para evitar que hagan cortes tan finos y memoricen casos individuales.
2. **Aumentar** `min_samples_leaf` (**Muestras Mínimas por Hoja**): Forzar a que los nodos finales tengan un número mínimo de muestras, impidiendo que el árbol cree reglas de decisión exclusivas para uno o dos clientes.



Pregunta 4: Interpretación de la U-Matrix en SOM (Semana 6)

Pregunta: "En un mapa auto-organizado (SOM), ¿qué representa físicamente la matriz de distancias U (U-Matrix) y cómo interpretas las zonas claras/altas frente a las zonas oscuras/bajas?"

- **Respuesta Ganadora:** La **U-Matrix** representa la distancia euclidiana entre los vectores de pesos de neuronas vecinas en el mapa.
- **Interpretación:**
 - **Zonas oscuras/bajas (Valles):** Representan neuronas que están muy cerca en el espacio de características. Indican la presencia de un **cluster** (datos con características muy homogéneas).
 - **Zonas claras/altas (Fronteras o Montañas):** Representan grandes distancias entre neuronas vecinas. Actúan como **barreras divisoras** que separan a los diferentes grupos o clusters.



Pregunta 5: La reina de las preguntas: Precision vs. Recall (Semana 7)

Pregunta: "En el contexto bancario, explica detalladamente qué métrica priorizarías (Precision o Recall) para los siguientes dos proyectos y por qué: 1) Clasificador de Spam en Correos Corporativos y 2) Detección de Fraude en Tarjetas de Crédito."

- **Respuesta Ganadora:**

1. Para el Filtro de Spam priorizo la PRECISIÓN:

- *Justificación:* Un falso positivo aquí significa clasificar un correo legítimo e importante (ej. de tu jefe o un cliente) como Spam. El costo de que el usuario no vea ese correo es altísimo. Prefiero dejar pasar algo de Spam a la bandeja principal (bajo recall) antes que perder correos cruciales (alta precisión).

2. Para la Detección de Fraude priorizo el RECALL:

- *Justificación:* Un falso negativo aquí significa dejar pasar una transacción fraudulenta sin detectarla. El costo financiero directo de la pérdida de dinero para el banco es enorme. Prefiero molestar a algunos clientes legítimos con llamadas de confirmación por falsas alarmas (falsos positivos / baja precisión) con tal de atrapar hasta el último fraude real (alto recall).